



GreenSense 4.0

Chatbot d'assistance aux techniciens (WS3)

Guide de présentation : points à aborder et fonctionnement du projet

Objet	Présenter le chatbot réalisé et le relier à l'étude « Connaissance et sources d'apprentissage de l'IA » (WS3)
Public	Encadrants et équipe PHOVA Technology
Durée conseillée	15 à 20 minutes, dont 5 minutes de démonstration
Comment lire ce guide	Chaque partie donne les points clés, puis une phrase « À dire » prête à l'emploi. Les parties 9 et 10 servent à la démonstration et aux questions.

1. Déroulé conseillé de la présentation

#	Partie	Durée	Message clé
1	Le besoin (document WS3)	2 min	Assister le technicien avant, pendant et après l'intervention, sans inventer.
2	La solution en une phrase	1 min	Un assistant RAG qui répond uniquement à partir des manuels, et cite ses sources.
3	Architecture	2 min	Application web + API Spring Boot + PostgreSQL/pgvector + OpenAI.
4	Le parcours d'une question	3 min	Normalisation, recherche des extraits, réponse ancrée, traçabilité.
5	Correspondance avec WS3	2 min	Ce qui est réalisé, partiel, ou à venir, exigence par exigence.
6	La boucle d'apprentissage	2 min	Chaque question est enregistrée avec ses extraits : base du futur apprentissage.
7	Évaluation et premiers résultats	2 min	51 cas de test et premières observations sur les données.
8	Limites et prochaines étapes	2 min	Retour technicien, données capteurs WS2, normes, sécurité des données.
9	Démonstration	5 min	Question texte, question vocale, question hors sujet.

2. Le besoin exprimé dans le document WS3

Le document WS3 définit le chatbot d'assistance aux techniciens du module « Plateforme de pilotage de la maintenance ». Périmètre : **20 pompes centrifuges** sur les sites de **Safi** et **Jorf Lasfar**. Les points à retenir :

- **Assister, pas remplacer** : le chatbot fournit rapidement l'information la plus pertinente ; le diagnostic reste humain.
- **Trois moments** : avant l'intervention (équipement, anomalie, causes probables), pendant (procédures, seuils, solutions déjà appliquées), après (recueil du retour technicien).
- **Quatre couches de connaissance** : technique générale, constructeur, capteurs / Digital Twin (WS2), interne capitalisée.
- **Pas d'apprentissage libre sur Internet** : une base interne validée, interrogée selon l'approche **RAG** (Retrieval-Augmented Generation), pour pouvoir **citer la source** de chaque réponse.
- **Apprentissage par l'interaction** : sollicitation, validation ou correction, enregistrement structuré, réentraînement périodique, enrichissement de la base.
- **Signaler les cas inédits** plutôt que de donner une réponse non fiable.

À dire : « Le document WS3 fixe une règle simple : le chatbot ne doit jamais inventer. Il répond à partir de documents validés, il cite sa source, et il apprend des retours des techniciens. Tout le projet a été construit autour de cette règle. »

3. La solution et son architecture

En une phrase : le technicien pose sa question (au clavier ou à la voix) ; le système retrouve les passages pertinents dans les manuels de la pompe concernée, et le modèle de langage rédige une réponse courte **uniquement à partir de ces passages**, en indiquant les documents utilisés.

Couche	Technologie	Rôle
Interface	React 19, Vite, Tailwind CSS	Application web utilisable sur téléphone : saisie texte, dictée vocale, historique.
API	Java 17, Spring Boot 3.4, Spring Security (JWT), Spring AI	Authentification, gestion des documents, chaîne RAG.
Base de données	PostgreSQL + extension pgvector	Documents, extraits vectorisés, journal des interactions.
IA	OpenAI : gpt-4o-mini (réponses), text-embedding-3-small (vecteurs), Whisper (voix)	Rédaction des réponses, recherche sémantique, transcription des questions dictées.
Cache	Redis	Une question déjà posée est servie sans nouvel appel au modèle (coût et délai).
Supervision	Prometheus + Grafana	Nombre de questions, taux de cache, temps de recherche et de vectorisation.
Déploiement	Docker Compose	Tous les services démarrent avec une seule commande.

Préparation des documents (ingestion)

- Le PDF est déposé via l'application, puis son texte est extrait (Apache PDFBox).
- Le texte est découpé en **extraits d'environ 500 mots**, avec **100 mots de chevauchement** pour ne pas couper une procédure en deux.
- Chaque extrait est transformé en **vecteur** (embedding) qui représente son sens, puis stocké dans PostgreSQL/pgvector.
- Documents actuellement chargés : manuel **AHLSTAR** (référence de la pompe **OTW**), manuel **HDX** (référence de la **PHB2**) et le rapport de présentation PHOVA.

À dire : « Un manuel de 100 pages devient une centaine d'extraits. Chaque extrait reçoit une empreinte numérique de son sens, ce qui permet de retrouver un passage même si le technicien n'utilise pas les mêmes mots que le manuel. »

4. Le parcours d'une question, étape par étape

Étape	Ce qui se passe	Pourquoi
1. Saisie	Question tapée, ou dictée puis transcrite par Whisper. Le vocabulaire des pompes (OTW, PHB2, garniture mécanique, NPSH...) est fourni à Whisper.	Sur site, le technicien a souvent les mains prises ; les codes de pompe sont mal reconnus sans ce vocabulaire.
2. Identification de la pompe	Le nom de la pompe PHOVA est reconnu (ex. OTW) et associé à la documentation constructeur de référence correspondante (ex. AHLSTAR).	La recherche est limitée aux manuels de cette pompe : les données d'une autre pompe ne peuvent pas se mélanger à la réponse.
3. Contrôle	Si deux pompes sont citées dans la même question, le système demande d'en choisir une.	Éviter une réponse qui mélange les caractéristiques de deux machines.
4. Recherche	La question est vectorisée ; pgvector renvoie les 12 extraits les plus proches , classés par distance, en une seule requête sur tous les fichiers de la pompe.	Seuls les passages pertinents sont transmis au modèle.
5. Réponse ancrée	Le modèle reçoit les extraits numérotés et des consignes strictes : répondre uniquement à partir des extraits, citer les chiffres exactement, lire les tableaux, interpréter une question mal formulée de façon bienveillante.	Pas de connaissance extérieure, pas de chiffre inventé.
6. Cas sans réponse	Si aucun extrait ne traite le sujet, le modèle répond « null » : le technicien est informé que la documentation ne couvre pas la question.	Exigence WS3 : signaler les cas inédits plutôt que répondre de façon non fiable.
7. Sources	La réponse se termine par la liste des documents utilisés. Le modèle indique aussi les numéros des extraits réellement utilisés (ligne masquée au technicien).	Traçabilité exigée par WS3.
8. Enregistrement	La question, la réponse, la pompe, le résultat et les 12 extraits (distance, rang, utilisé ou non) sont enregistrés.	Base de la boucle d'apprentissage (partie 6).

À dire : « Le point important est l'étape 5 : le modèle n'a pas le droit d'utiliser ce qu'il sait par ailleurs. S'il ne trouve rien dans les manuels, il le dit. C'est ce qui rend les réponses vérifiables. »

5. Correspondance avec les exigences du document WS3

Ce tableau est le cœur de la présentation : il montre honnêtement l'état d'avancement, exigence par exigence.

Exigence WS3	État	Ce qui existe aujourd'hui
Couche 1 : connaissance technique générale	Partiel	Couverte par le contenu des manuels constructeurs ; les normes (ISO 10816/20816, API 610) ne sont pas encore chargées.
Couche 2 : connaissance constructeur	Réalisé	Manuels AHLSTAR (OTW) et HDX (PHB2) chargés ; recherche limitée aux manuels de la pompe citée.
Couche 3 : capteurs / Digital Twin (WS2)	À venir	Dépend de la livraison des données WS2 (vibration, température, pression, débit, courant moteur).
Couche 4 : connaissance interne capitalisée	En cours	Chaque interaction est enregistrée ; le retour du technicien reste à brancher.
Répondre sur une procédure	Réalisé	Réponses courtes, chiffres cités à l'identique.
Proposer des causes probables	Partiel	Possible quand le manuel décrit la panne ; sans données capteurs ni historique, le diagnostic reste limité.
Suggérer une solution déjà validée	À venir	Nécessite l'historique des interventions et les retours techniciens.
Orienter vers le document pertinent	Réalisé	Ligne « sources » en fin de réponse.
Signaler les cas inédits	Réalisé	Réponse « null » quand la documentation ne couvre pas le sujet.
Pas d'apprentissage libre sur Internet (RAG)	Réalisé	Le modèle ne répond qu'à partir des extraits fournis.
Traçabilité de chaque recommandation	Réalisé	Sources affichées ; extraits utilisés enregistrés en base.
Boucle §5 : 1. Sollicitation	Réalisé	Texte et voix.
Boucle §5 : 2. Validation ou correction	À venir	Point d'entrée « feedback » prévu, pas encore actif.
Boucle §5 : 3. Enregistrement structuré	Réalisé	Table des interactions et table des extraits utilisés.
Boucle §5 : 4 et 5. Réentraînement, enrichissement	À venir	Possible une fois les retours validés accumulés.
Vigilance : sécurité des données (LLM tiers)	Partiel	Les extraits sont envoyés à OpenAI ; point à arbitrer avec PHOVA (voir partie 8).

À dire : « Le socle demandé par WS3 est en place : réponses ancrées, sources citées, cas inédits signalés, et enregistrement structuré. Ce qui manque dépend surtout de données qui n'existent pas encore : les retours des techniciens et les mesures du Digital Twin. »

6. La boucle d'apprentissage : ce qui est déjà enregistré

Le document WS3 identifie le manque d'historique comme la contrainte principale, et l'interaction technicien comme la source la plus stratégique. Chaque question est donc enregistrée de façon structurée :

Donnée enregistrée	À quoi elle sert
Question brute et question normalisée	Voir comment les techniciens formulent réellement leurs questions.
Pompe concernée	Mesurer la qualité des réponses pompe par pompe.
Résultat : répondu, sans réponse, aucun extrait trouvé, plusieurs pompes	Distinguer un manque de documentation d'une erreur de recherche ou d'un refus du modèle.
Les 12 extraits transmis, avec leur distance et leur rang	Évaluer la qualité de la recherche : les bons passages arrivent-ils en tête ?
Extrait utilisé ou non par le modèle	Savoir combien d'extraits envoyer et repérer les passages inutiles.
Version du prompt	Comparer les résultats avant et après chaque modification des consignes.
Verdict et correction du technicien (à brancher)	Transformer les réponses validées en références réutilisables.

Distance et rang, en termes simples

- **Distance** : proximité de sens entre la question et l'extrait. Proche de 0 : très pertinent ; au-delà de 0,4 environ : correspondance faible.
- **Rang** : position de l'extrait dans le classement (0 = le plus proche). Le numéro d'extrait cité par le modèle correspond directement au rang.

À dire : « Aujourd'hui, chaque question est déjà une donnée d'apprentissage. Quand les techniciens valideront ou corrigeront les réponses, ces lignes deviendront un jeu de données étiqueté, exactement la boucle décrite au paragraphe 5 du document WS3. »

7. Évaluation et premières observations

Jeu de test

Un jeu de **51 cas de test** interroge automatiquement l'application réelle. Chaque cas contient une question, la valeur attendue dans la réponse (tirée des manuels) et le document source. Il couvre :

- des valeurs précises (ex. intervalle de vidange d'huile de la PHB2 : 4000 heures ; surépaisseur de corrosion de l'OTW : 3,0 mm) ;
- des questions sur l'entreprise, sans nom de pompe ;
- des questions mal formulées, en français, ou mal transcrites (« O.T.W ») ;
- des questions hors sujet ou non documentées, qui doivent être refusées ;
- des questions citant deux pompes, qui doivent être rejetées.

Exemple observé sur une question générale

Question : « how do you maintain a pump in general ? ». Le modèle a utilisé les extraits de rang **1, 2, 6 et 11**, issus de deux manuels, et **pas** l'extrait de rang 0. Enseignements provisoires :

- Réduire le nombre d'extraits envoyés ferait perdre des passages utiles : le rang 11 a servi.
- Le passage le plus proche n'est pas toujours le plus utile : piste d'un reclassement (reranker) pour la suite.
- Certains extraits contiennent des en-têtes et pieds de page répétés du manuel, qui brouillent la recherche : piste de nettoyage à l'ingestion.

- Une seule question ne suffit pas : ces constats seront confirmés ou non sur plusieurs centaines de questions.

8. Limites actuelles et prochaines étapes

Limite	Conséquence	Prochaine étape
Retour technicien non branché	Pas encore de réponses validées ou corrigées.	Activer le point d'entrée « feedback » (confirmer / corriger / rejeter) dans l'application.
Fiches produit PHOVA inaccessibles quand une pompe est citée	« Débit maximal de l'OTW ? » cherche seulement dans le manuel de référence, pas dans la fiche PHOVA.	Inclure les documents PHOVA de la pompe dans la recherche.
Pompes sans documentation chargée (OTC, OTS, PHB3, PHH)	Aucun extrait trouvé : pas de réponse possible.	Charger les manuels de référence correspondants.
En-têtes et pieds de page dans les extraits	Recherche moins précise.	Nettoyer le texte avant découpage.
Normes non chargées	Couche 1 incomplète.	Charger ISO 10816/20816 et API 610 (sous réserve des droits d'usage).
Pas de données capteurs	Couche 3 absente, diagnostic limité.	Intégrer les données du Digital Twin (WS2).
Modèle de langage externe (OpenAI)	Des extraits de manuels quittent l'infrastructure.	Arbitrer avec PHOVA : accord de traitement des données, ou modèle hébergé en interne.

À dire : « Les limites sont connues et mesurées. Les deux priorités sont le retour technicien, qui ferme la boucle d'apprentissage, et l'intégration des données du Digital Twin, qui permettra de passer de l'aide documentaire à l'aide au diagnostic. »

9. Script de démonstration (5 minutes)

#	Action	Ce qu'il faut montrer
1	Se connecter, montrer la page « Que voulez-vous savoir ? »	Interface en français, utilisable sur téléphone.
2	Taper : « Quelle est la fréquence de vidange d'huile de la pompe PHB2 ? »	Réponse courte avec le chiffre exact (4000 heures) et la ligne « sources ».
3	Dictier : « pression eau de barrage garniture OTW »	Transcription vocale, puis réponse malgré une question très courte.
4	Taper : « Quelle est la capitale de la France ? »	Le chatbot refuse : il ne répond pas hors de sa documentation.
5	Taper : « Compare OTW et PHB2 »	Le chatbot demande de choisir une seule pompe.
6	(Optionnel) Montrer la table des interactions en base	Question, résultat, extraits, distances, extraits utilisés.

Conseil : faire les questions 2 à 5 une fois avant la présentation. Grâce au cache, elles répondront ensuite instantanément pendant la démonstration.

10. Questions probables et éléments de réponse

Q : Pourquoi ne pas entraîner directement un modèle sur les manuels ?

R : Le RAG permet de citer la source exacte, d'ajouter un document sans réentraînement, et limite les réponses inventées. C'est l'approche recommandée par le document WS3.

Q : Que se passe-t-il si la réponse n'est pas dans les documents ?

R : Le modèle répond qu'il n'a pas l'information (« null »), conformément à l'exigence de signaler les cas inédits.

Q : Comment savez-vous que les réponses sont justes ?

R : Par le jeu de 51 cas de test avec valeurs attendues, et bientôt par la validation des techniciens.

Q : Les données de PHOVA sont-elles en sécurité ?

R : Les extraits pertinents sont envoyés à OpenAI pour rédiger la réponse. C'est un point de vigilance du document WS3, à arbitrer : accord de traitement des données ou modèle hébergé en interne.

Q : Combien coûte une question ?

R : Le modèle utilisé (gpt-4o-mini) est l'un des moins coûteux, et les questions répétées sont servies par le cache Redis sans nouvel appel.

Q : Comment le chatbot va-t-il s'améliorer ?

R : Chaque question est déjà enregistrée avec ses extraits. Avec les retours des techniciens, on saura quelles réponses sont justes, et on pourra améliorer la recherche, les consignes, puis enrichir la base.